Лабораторная работа №5
Линейная регрессия с L1-регуляризацией

1. Что сделано

Написаны четыре варианта обучения: последовательный, OpenMP, SIMD и OpenMP + SIMD. На каждом шаге программа считает ошибки прогноза и меняет веса, L1-регуляризация уменьшает веса и может сделать их нулевыми, потоки обрабатывают разные объекты, SIMD ускоряет циклы по признакам.

Компьютер: Intel Core i7-11800H, 8 ядер и 16 потоков. Windows, GCC 16.2.0. Основные флаги: -O3 -march=native -fopenmp.

Обычные параметры: 100000 объектов, 32 признака, 60 шагов обучения и 8 потоков. Шаг обучения eta = 0,5, регуляризация lambda = 0,01. Данные созданы с seed = 42, начальные веса равны нулю. Для каждого замера взята медиана пяти запусков после прогрева. Подготовка данных и вывод результатов во время обучения не входят.

2. Проверка результатов

Сначала варианты проверены на 1000 объектах и 32 признаках.

Вариант	Функция потерь F	Наибольшая разница весов
Последовательная	0,0394291062	0,000e+00
OpenMP	0,0394291062	1,110e-16
SIMD	0,0394291062	0,000e+00
OpenMP + SIMD	0,0394291062	1,110e-16

Во всех опытах результаты совпали с точностью 1e-8. Самая большая разница весов составила 1,33e-15.

3. Сравнение времени обучения

Вариант	Время, с	Ускорение
Последовательная	0,137	1,00
OpenMP	0,056	2,45
SIMD	0,096	1,43
OpenMP + SIMD	0,030	4,57

Ускорение показывает, во сколько раз вариант быстрее последовательного.

4. Число объектов N

N	Послед., с	OpenMP, с	SIMD, с	OpenMP + SIMD, с
10000	0,009	0,008	0,006	0,007
100000	0,137	0,056	0,096	0,030
1000000	1,355	0,482	1,063	0,432

Здесь 32 признака. На 10000 объектах быстрее SIMD без потоков. На больших наборах быстрее OpenMP + SIMD.

5. Число признаков d

d	Послед., с	OpenMP, с	SIMD, с	OpenMP + SIMD, с
8	0,032	0,013	0,021	0,013
32	0,137	0,056	0,096	0,030
128	0,749	0,188	0,380	0,152
256	1,869	0,338	1,012	0,315

6. Число потоков

В этих опытах 100000 объектов и 32 признака. Ускорение S считается относительно одного потока того же варианта. Эффективность E = S / число потоков.

Потоки	OpenMP, с	S	E	OpenMP + SIMD, с	S	E
1	0,139	1,00	1,00	0,098	1,00	1,00
2	0,105	1,32	0,66	0,076	1,29	0,64
4	0,068	2,04	0,51	0,042	2,33	0,58
8	0,056	2,48	0,31	0,030	3,27	0,41
16	0,048	2,90	0,18	0,033	2,97	0,19

Для OpenMP + SIMD лучший результат дали 8 потоков. При 16 потоках время немного выросло. На запуск потоков и обмен данными тоже тратится время, поэтому ускорение меньше числа потоков.

7. Сила регуляризации lambda

Данные и настройки обучения одинаковы. Время указано для OpenMP + SIMD. Вес считается практически нулевым, если его модуль меньше 1e-6.

lambda	Функция потерь F	Нулевых весов из 32	Время, с
0	6,6592e-05	0	0,030
0,0001	0,000466557	28	0,032
0,001	0,00406063	28	0,039
0,01	0,039467	28	0,030
0,1	0,340088	28	0,030

Без регуляризации нулевых весов нет. Уже при lambda = 0,0001 их стало 28. Дальше число нулей не менялось. F выросла, так как в неё входит штраф за веса.

8. Оптимизации компилятора

Все запуски здесь однопоточные. В каждой сборке используется -fopenmp.

Настройки	Время, с	Ускорение к -O0
-O0	0,799	1,00
-O3	0,175	4,57
-O3 -march=native	0,137	5,83
-O3 -march=native и omp simd	0,096	8,32

По отчёту GCC циклы расчёта прогноза и градиента используют SIMD даже без явных директив. С omp simd эти циклы тоже векторизованы. GCC использует векторы по 32 байта. Для внешних циклов он указывает причины отказа: несколько вложенных циклов, сложный доступ к памяти и синхронизация потоков.

9. Вывод

На больших наборах быстрее всего OpenMP + SIMD. При обычных параметрах он ускорил обучение в 4,57 раза. Увеличение числа потоков с 8 до 16 уже не помогло. Регуляризация обнулила 28 весов из 32.